# 巨量資料探勘與應用

HW3

## 一、組員名單與分工

資工碩一 112598017 楊淨雯 資工碩一 112598028 余珮綺

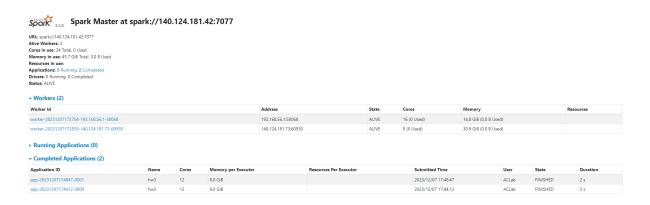
## 二、環境設定

#### Multi-node on spark

master 和 worker 皆為 windows, 一樣都要先照之前的作業把 python、spark、hadoop 安裝好

master: 140.124.181.42

worker 1: 192.168.56.1, 4 cores, 8GB Used worker 2: 140.124.181.73, 8 cores, 16GB Used



## 三、實驗執行說明

## Step1. 連線

• Master:

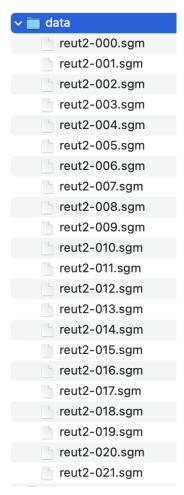
以 Admin 開啟 cmd, 到 spark \ bin 資料夾, 輸入指令:
spark-class org.apache.spark.deploy.master.Master
直到出現 Alive 即可

• worker:

以 Admin 開啟 cmd, 到 spark \ bin 資料夾, 輸入指令: spark-class org.apache.spark.deploy.worker.Worker spark://<mark><master\_ip></mark>:7077

## Step2. 執行

● 確保指定路徑中的資料夾裡有以下這些檔案



- 打開 cmd, 進入spark \ bin 資料夾
- 輸入 spark-submit --master spark://http://<master\_ip>:7077 --executor-cores 4
   --executor-memory 8g <code\_file\_name>

#### 附註:

在我們的電腦上 <master\_ip> 為 140.124.181.42 <code\_file\_name> 為 hw3.py 畫底線部分為分配worker資源

要下載作業有用到的額外套件: Pandas

## 四、實驗結果

1

# 成功將 Char\_Mat 表格輸出成 CSV 檔案,檔案路徑為: out\_csv

part-00000-44811434-f3f2-44d4-b264-662cdb840c11-c000 0.00, 0.0057045703 

#### 2.

+	<del></del>	H
hash	count	
[3.2867133E7]	2	г 
[1.5545498E7]	2	
[7731514.0]	2	
[7.4627246E7]	3	
[1.6571645E7]	4	
[1.3728635E7]	2	
[6212580.0]	5	
[1.9857206E7]	12	
[1.714317E7]	17	
[7 <b>.</b> 1483169E7]	8	
[3.7458825E7]	5	
[6404769 <b>.</b> 0]		
[2661413.0]	4	
[9077028.0]		
[9135768.0]	2	
[1.2684948E7]	3	
[5 <b>.</b> 9734509E7]	2	
[1689089.0]	2	
[1.0006493E8]	22	
[3.504417E7]	7	
++		
only showing to	op 20 i	rows